

Redes neuronales convolucionales para Interfaz Cerebro-Máquina basada en imágenes motoras

Javier Enrique Pérez López

Resumen

Las Interfaces Cerebro-Máquina (BMI) se basan en algoritmos de clasificación de *machine learning*. Anteriormente, los modelos de *deep learning* habían sido utilizados pocas veces en BMI porque los conjuntos de datos disponibles eran pequeños. En este trabajo se comparan cuatro arquitecturas de redes neuronales convolucionales en un conjunto de datos considerablemente mayor que los disponibles anteriormente. Se determinó que el mejor modelo es EEGNet [5] que realiza *depthwise separable convolutions*.

Introducción

Una Interfaz Cerebro-Máquina (BMI) es un sistema que traduce los patrones de la actividad cerebral en comandos que permiten controlar dispositivos o aplicaciones [1]. Una BMI basada en imágenes motoras utiliza la actividad inducida en la corteza motora que se realiza mediante la imaginación de un movimiento, sin recibir estímulo externo ni realizándolo [2]. Actualmente, se utilizan algoritmos de clasificación para discriminar entre las diferentes clases de imágenes motoras [1]. Sin embargo, los conjuntos de datos disponibles son muy limitados por lo que no reflejan la complejidad de la tarea. El objetivo de este trabajo es evaluar y comparar el desempeño de algoritmos de redes convolucionales en la decodificación de señales de EEG para BMI en un conjunto de datos grande.

Materiales y Métodos

Conjunto de datos: A large electroencephalographic motor imagery dataset for electroencephalographic brain computer interfaces [3].

Paradigmas de imágenes motoras:

❖ **CLA**

- 3 clases (mano izquierda, mano derecha, neutral).
- 17 sesiones de registro (7 participantes).

❖ **HaLT**

- 6 clases (mano izquierda, mano derecha, neutral, pierna izquierda, pierna derecha, lengua).
- 29 sesiones de registro (12 participantes).

Modelos: Shallow ConvNet [4] (línea de base), Deep ConvNet [4], EEGNet [5], Our (inspirado en SqueezeNet [6]).

Entrenamiento: Un modelo por paradigma y por sesión (184 modelos en total). Cada sesión tiene 1000 ejemplos aprox. (entrenamiento: 600, validación: 200, prueba: 200).

Evaluación: Average Classification Accuracy (ACA).

Resultados

	CLA (ACA)			
	Shallow	Deep	EEGNet	Our
Mean	0.75	0.76	0.80	0.80
SD	0.13	0.14	0.11	0.11

Promedio y desviación estándar del ACA de los modelos entrenados en el paradigma CLA.

	HaLT (ACA)			
	Shallow	Deep	EEGNet	Our
Mean	0.61	0.64	0.67	0.64
SD	0.19	0.19	0.18	0.20

Promedio y desviación estándar del ACA de los modelos entrenados en el paradigma HaLT.

Discusión

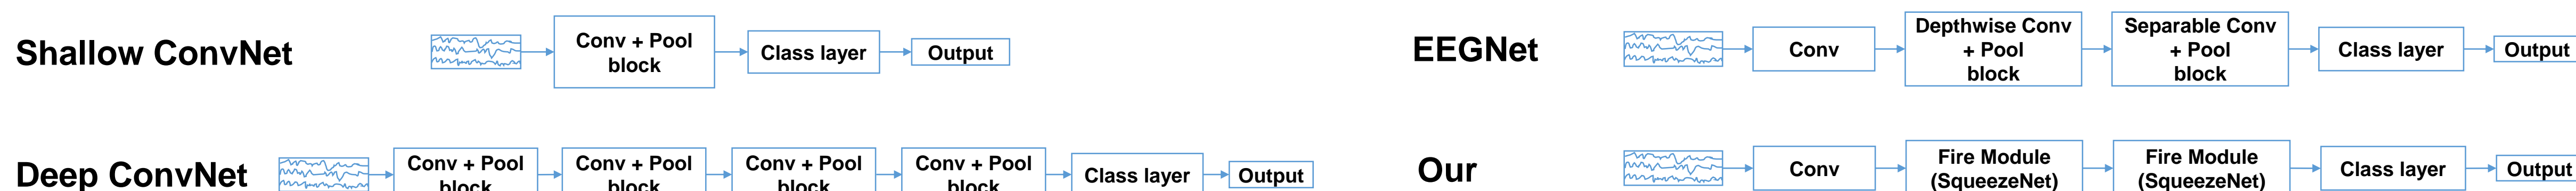
EEGNet con *depthwise separable convolutions* y nuestro modelo (Our) con *fire module* de SqueezeNet obtuvieron el mejor desempeño en el paradigma CLA (3 clases). EEGNet tuvo el mejor desempeño en HaLT (6 clases).

Los modelos muestran una gran variabilidad en el desempeño: algunas sesiones son más difíciles (o más fáciles) de entrenar.

Conclusiones

Se mostró la eficacia de modelos de redes convolucionales que incorporan módulos inspirados por redes que tienen un buen desempeño en aplicaciones de visión móvil.

Como trabajo futuro, se plantea desarrollar nuevas arquitecturas de redes convolucionales que incorporen módulos eficientes similares. Además, se pueden incorporar hiperparámetros que varíen dependiendo de la sesión.



Agradecimientos: Prof. Mario Valderrama, Prof. Pablo Arbeláez, Google Colaboratory, Christian Picón.

Referencias

- [1] F. Lotte, L. Bougrain, A. Cichocki, M. Clerc, M. Congedo, A. Rakotomamonjy, and F. Yger, "A review of classification algorithms for EEG-based brain-computer interfaces: a 10 year update.," *Journal of neural engineering*, vol. 15, no. 3, p. 031005, 2018.
- [2] H. Cho, M. Ahn, M. Kwon, and S. C. Jun, "A step-by-step tutorial for a motor imagery-based BCI," in *Brain-Computer Interfaces Handbook*, pp. 445–460, CRC Press, Jan. 2018.
- [3] M. Kaya, M. K. Binli, E. Ozbay, H. Yanar, and Y. Mishchenko, "A large electroencephalographic motor imagery dataset for electroencephalographic brain computer interfaces," *Scientific Data*, vol. 5, Oct. 2018.
- [4] R. T. Schirrmeister, J. T. Springenberg, L. D. J. Fiederer, M. Glasstetter, K. Eggenberger, M. Tangemann, F. Hutter, W. Burgard, and T. Ball, "Deep learning with convolutional neural networks for EEG decoding and visualization," *Human Brain Mapping*, vol. 38, pp. 5391–5420, Aug. 2017.
- [5] V. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung, and B. Lance, "EEGnet: A compact convolutional network for EEG-based brain-computer interfaces," *Journal of neural engineering*, vol. 15 5, p. 056013, 2018.
- [6] F. N. Iandola, M. W. Moskewicz, K. Ashraf, S. Han, W. J. Dally, and K. Keutzer, "Squeezenet: Alexnet-level accuracy with 50x fewer parameters and <1mb model size," *ArXiv*, vol. abs/1602.07360, 2017.

Código

disponible en
Google Colab:

https://colab.research.google.com/drive/1KSrQxCKPChR3EEnE6zliPr_bWvgMhcFf?usp=sharing